

Relatório Técnico

Objetivo



Analisar a base de dados sobre exames câncer de mama do estado de Wisconsin/US e prever novos exames se são ou não identificados nódulos malignos. Para isso foi utilizada uma base do Kaggle (<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>) que contém 33 colunas e 568 linhas. Fui incluído no código (como comentário) a opção de rodar com a base inserida localmente por meio de download, dando opção ao usuário.

Estratégias de Pré-processamento

Primeiro foi realizada a conferência da base para ver se tinham colunas com dados inválidos e foi localizada uma coluna sem dados, que foi prontamente deletada. Posteriormente, os dados do diagnósticos que eram por letras (B/M) foi transformado em dados binários (0/1) em uma nova coluna. Também foram observados se os dados estavam em formato correto, o que não demandou tratamento específico.

Modelos Escolhidos e Justificativas

Para escolher os modelos do teste, foram realizadas uma Matriz de correlação para verificar se quais as colunas (informações do exame) tinham mais impacto entre si e um mapa de calor. Para o mapa de calor foi feito tanto para a base completa quanto também para os casos que já tinham sido diagnosticados como malignos (1) no intuito de verificar se havia alguma diferenciação na matriz de correlação. O estudo comparativo entre os mapas de calor foi utilizado para verificar se as principais correlações associadas aos tumores malignos permaneciam relevantes dentro da classe positiva, auxiliando a seleção de variáveis e a construção dos modelos de regressão. Pois entende-se que é muito mais arriscado um diagnóstico errado de não detecção de um câncer, pois levaria ao não tratamento da doença.



Com base nas correlações observadas nos dois mapas de calor ficou-se decidido o uso da Regressão Logística e da Árvore de Decisão (relações não lineares entre os

dados), pois atuam de forma distinta na análise das correlações, o que traria diversidade para ter uma análise mais satisfatória.

Para Regressão Logística tiramos as variáveis cujas correlações eram muito próximas de 0 (entre 0.1 e -0.1) pois o impacto era muito pequeno e tivemos de escalonar os dados, do contrário o código dava erro que impossibilitava a análise.


Já para a Árvore de Decisão não foi necessário fazer tratamentos específicos, em razão das características dos cálculos matemáticos.

Resultados Obtidos

Dados da Regressão Logística

Dados da Regressão Logística				
	precision	recall	f1-score	support
0	0.97	0.99	0.98	72
1	0.98	0.95	0.96	42
accuracy			0.97	114
macro avg	0.97	0.97	0.97	114
weighted avg	0.97	0.97	0.97	114

ROC-AUC: 0.996362433862434



Dados da Árvore de Decisão

Dados da Árvore de Decisão

```
Classification Report:
              precision    recall  f1-score   support

     0       0.92        0.96       0.94         72
     1       0.92        0.86       0.89         42

 accuracy          0.92          114
 macro avg         0.92          114
 weighted avg      0.92          114
```

ROC-AUC: 0.9173280423280423

Matriz de Confusão:

```
[[69  3]
 [ 6 36]]
```

Pela comparação entre o relatório de classificação dos dois modelos, foi-se observado que a Regressão Logística foi mais assertiva na análise. Foi incluída a Matriz de Confusão justamente para identificar os dados de Falsos Positivos e Falsos Negativos que poderiam levar a tratamentos equivocados da doença.

Comparação entre Modelos

Para o melhor entendimento dos resultados, as informações dos dois modelos passaram pelo Importance feature e SHARP.

Nos dois testes o modelo da Regressão Logística foi mais assertivo, primeiro por utilizar um número maior de variáveis e de forma mais estável, enquanto a Árvore de Decisão se concentrou em pouquíssimas variáveis, praticamente zerando às demais. Com isso este modelo deixou de considerar vários aspectos indicativos da doença.


Importance features - Regressão Logística


	feature	coef	abs_coef
17	texture_worst	1.201261	1.201261
9	radius_se	1.126305	1.126305
16	radius_worst	0.992504	0.992504
24	symmetry_worst	0.972894	0.972894
19	area_worst	0.957376	0.957376
12	compactness_se	-0.905415	0.905415
22	concavity_worst	0.902788	0.902788
7	concave points_mean	0.885902	0.885902
11	area_se	0.866162	0.866162
18	perimeter_worst	0.829521	0.829521
23	concave points_worst	0.777632	0.777632
6	concavity_mean	0.670573	0.670573
20	smoothness_worst	0.662142	0.662142
10	perimeter_se	0.658194	0.658194
5	compactness_mean	-0.583160	0.583160
14	concave points_se	0.582106	0.582106
1	texture_mean	0.575006	0.575006
15	fractal_dimension_se	-0.515797	0.515797
3	area_mean	0.491704	0.491704
0	radius_mean	0.436820	0.436820
2	perimeter_mean	0.421473	0.421473
4	smoothness_mean	0.329480	0.329480



Importance features- Árvore de Decisão

	feature	importance	
22	perimeter_worst	0.746810	
27	concave points_worst	0.069915	
1	texture_mean	0.043959	
24	smoothness_worst	0.032669	
11	texture_se	0.024569	
3	area_mean	0.023187	
23	area_worst	0.016117	
6	concavity_mean	0.011638	
21	texture_worst	0.009698	
20	radius_worst	0.009698	
26	concavity_worst	0.009433	
13	area_se	0.002307	
5	compactness_mean	0.000000	
0	radius_mean	0.000000	
12	perimeter_se	0.000000	
10	radius_se	0.000000	
8	symmetry_mean	0.000000	
9	fractal_dimension_mean	0.000000	
7	concave points_mean	0.000000	
2	perimeter_mean	0.000000	





Uso de PCA na Regressão Logística

Após de definição que a Regressão Logística era a mais assertiva para a demanda exposta e tendo em vista a possibilidade de melhoria dos falsos positivos e negativos, foi utilizada a estratégia de PCA para verificar possíveis melhorias nos resultados.

Como se tratava de 29 variáveis distintas, a PCA era opção por reduzir a quantidade de variáveis de uma forma equilibrada e que indicasse as mais assertivas sem a necessidade da escolha manual que poderia suscitar erros.

Para isso foi realizada uma análise dos componentes e decidiu-se pelo uso de 10 componente que representa aproximadamente 95% das variáveis.

Depois disso, foi realizada uma nova Regressão Logística com esse critério que chegou nos seguintes resultados:



```
Dados Regressão Logística PCAS
Accuracy: 0.9912280701754386
      precision    recall  f1-score   support

     0       0.99      1.00      0.99        72
     1       1.00      0.98      0.99        42

 accuracy          0.99          0.99          0.99        114
 macro avg         0.99          0.99          0.99        114
 weighted avg      0.99          0.99          0.99        114

Matriz de Confusão
[[72  0]
 [ 1 41]]
```

Os resultados da técnica de Regressão Logística com uso de PCA diminuiu os casos de falsos negativos e falsos positivos além de melhorar os resultados gerais da análise.



Conclusão Final

A análise de dados demonstrou de uma precisão interessante sobre as predições das bases existentes, todavia por se tratar de uma base ainda pequena (568 linhas) torna-se insuficiente a pesquisa para transformar o modelo preditivo em uso comercial.

Entendemos também que foram utilizados somente dados numéricos dos exames, o ideal seria comparar com dados de imagem que por protocolo são solicitadas pelos médicos e combinadas com outros exames laboratoriais (marcadores específicos relacionados à doença) assim, poderá ter um diagnóstico preditivo muito mais robusto.